

从传统机器学习到多模态大模型 的手写数学公式识别

数据挖掘与机器学习 · 课程项目汇报

小组成员：张椅达 · 杨振凯 · 钟京序

2026年5月

目录

01 项目背景与目标

02 数据集与数据探索

03 传统机器学习路线

04 多模态大模型路线

05 对比学习探索

06 实验结果与对比

07 矩阵识别分析

08 模型部署

09 小组分工

核心问题

手写数学公式识别是文档数字化的核心挑战。与普通文字识别不同，数学公式具有二维空间结构（分式、根号、上下标、矩阵），传统OCR难以应对。

技术路线：三条路线的探索

传统机器学习 ✓

HOG+LBP+PCA+SVM
分类范式 · 68.73%

对比学习 ✕ 探索后放弃

CNN编码器+最近邻检索
检索范式 · 仅返回已知公式

多模态大模型 ✓

TrOCR+LoRA+DeepSeek
生成范式 · 85.2%

核心目标：系统比较传统机器学习与多模态大模型在公式识别任务上的性能差异

CROHME 数据集

训练 2011 921 样本 · 含真值	训练 2012-2013 19,880 样本 · 含真值	矩阵 2014 512+244 样本 · 含真值	总计 22,021 样本 5,317 唯一LaTeX类
--	--	--	---

数据格式：InkML

```
<trace> 456,341 520,380 580,395 ... </trace>  
  
<annotation type="truth"> \sin x + \cos y </annotation>
```

关键发现

类别长尾分布：Top-30高频类 vs 5,287低频类
矩阵公式因多样性极高在Top-N筛选中被淘汰

传统ML：48×48+数据增强+Top-30筛选	大模型：448×448（面积87倍）+无过滤全量使用
--------------------------	----------------------------

技术流水线

图像 → HOG(900维) + LBP(10维) → PCA(303维) → SVM分类 → 结果

特征工程

HOG 方向梯度直方图

- 统计图像局部区域梯度方向分布
- 参数：orientations=9, ppc=8, cpb=2
- 输出：900维 → 捕获边缘方向特征

LBP + PCA

- LBP：局部二值模式，10维纹理特征
- 融合：HOG(900)+LBP(10)=910维
- PCA：保留95%方差 → 303维

SVM 分类器 & 结果

LinearSVC (C=0.039) CV: 66.99% 测试: 68.73%

RBF (C=0.356, gamma=0.001) CV: 66.67%

工程难点：GridSearch不可行→RandomizedSearchCV

14张可视化分析图

样本网格图 / HOG可视化 / PCA方差曲线

混淆矩阵热力图 / 各类准确率 / 误分类分析

为什么不能直接使用DeepSeek?

尝试一（视觉API）：70%请求失败

→ API不支持图像输入

尝试二（文本坐标）：无法理解空间结构

→ 坐标过于抽象

混合方案架构

InkML → 图像渲染(448x448)

→ TrOCR + LoRA（视觉识别第一步）

→ 初步 LaTeX

→ DeepSeek 文本API（语义校正第二步）

TrOCR 模型架构

ViT 编码器

448x448图像→16x16 patches→Linear Projection→Transformer编码

作用：将视觉信息转化为特征向量（"看懂"图像）

RoBERTa 解码器

自回归逐个生成LaTeX token

作用：将特征向量"翻译"为LaTeX字符串

334M参数 · 预训练：MathWriting合成数据 · 基座：tjoab/latex_finetuned

04

LoRA 微调 + DeepSeek 校正

LoRA 低秩适配微调（核心算法）

LoRA 原理

$$W' = W + BA$$

冻结原始权重W → 训练低秩适配器B、A
rank=8 → 只训练 0.3% 参数

对比维度	全量微调	LoRA微调	本项目配置
训练参数量	334M (100%)	1M (0.3%)	rank=8, alpha=16, target=q+v
GPU显存	> 16GB	~4GB	RTX 4060 (8GB)

DeepSeek 语义校正

语法修正

补充缺失反斜线
`sin → \sin`

语义推断

根据上下文纠正数字/变量
`z^x → 2^x`

结构优化

修正括号匹配/上下标
`cos^2 → cos^4`

训练：700样本·8轮·7分钟·~20%→80.8%

+DeepSeek校正：80.8%→85.2% (+4.4%)

什么是对比学习？

核心思想：拉近同类样本，推远异类样本

- Anchor（锚点）：待查询的图像
- Positive（正样本）：同公式的增强图像
- Negative（负样本）：不同公式的图像
- 训练目标：InfoNCE 损失函数

本项目实现

- 编码器：4层CNN+128维投影头
- 参数：约1.5M，CPU可训

检索流程：

测试图像 → 编码器 → 128维向量
→ 最近邻搜索 → 返回已有LaTeX

为什么放弃此方案？

① 检索式本质限制

只能返回训练集中已有的公式——与传统ML同样的封闭类别问题

② 任务需求不匹配

需要"生成"任意公式而非"检索"已有公式 → 选择生成式方案

辅助工作：文献调研、词表整理、结构特征验证、特征缓存构建

85.2%

多模态大模型（全量921样本）

LoRA 80.8% + DeepSeek +4.4%

传统ML (30类)
68.73%

传统ML (10类·64x64)
77.78%

性能提升历程

原始LaTeXify → ~20%

数据不匹配 → ~16%

LoRA初版 → 71%

+DeepSeek → 85.2%

评估指标

传统ML

- 分类准确率（无LaTeX归一化）
- 混淆矩阵 · F1-score

多模态大模型

- Exact Match（归一化）· CER · BLEU
- LaTeX归一化（5类等价差异处理）

验证集（221样本未参与训练）：LoRA 72.4% → +DeepSeek 74.7%

传统ML：无法识别（0%）

根本原因：分类范式限制

- 每个LaTeX字符串是独立类别
- 不同矩阵 → 不同类 → 组合爆炸

代码证据：Top-N频率过滤

```
load_filtered(min_samples=10)
```

- 高频类 135样本/类（普通公式）
- 矩阵类 1-5样本/类 → 被过滤淘汰

结论：分类范式与矩阵识别不可解矛盾

多模态大模型：45.9%

生成范式的三大优势

- ① 自回归生成
逐个token生成，不受预定义类别限制
- ② 共享子结构学习
`\begin{pmatrix}`结构一次学会到处可用
- ③ 全量数据利用
无Top-N截断，低频矩阵也参与训练

矩阵结构多数能正确生成

主要错误在内部数字精度

核心结论：分类范式（封闭类别→矩阵不可识别）≠ 生成范式（开放生成→矩阵可识别45.9%）

这不是准确率高低的量变，而是“能不能做”的质变

维度	传统机器学习	多模态大模型	差异
方法	HOG+LBP+PCA+SVM	TrOCR+LoRA+DeepSeek	—
范式	分类 Classification	生成 Generation	质变
最高准确率	68.73% (30类)	85.2% (全量921)	+16.5pp
矩阵识别	无法识别	45.9%	从无到有
类覆盖	Top-30类	全量921样本	30倍
训练时间	~34min CPU	~7min GPU+API	各有优势
图像分辨率	48x48	448x448	面积87倍
硬件需求	任意CPU	GPU 4GB+/API	门槛不同
外部依赖	无 (免费离线)	API付费+模型下载	成本差异
核心优势	可解释·低成本·易部署	高精度·强泛化·可生成	互补

两条路线互补：传统ML适合受限场景 · 大模型适合高精度开放场景

传统ML独立部署

```
python preprocess.py
python traditional_model.py
python quick_test.py
```

环境：任意CPU · 离线免费 · 无需API

多模态大模型部署

```
# LoRA+DeepSeek混合方案
python main.py --mode lora_refine
# 仅LoRA推理（无API）
python main.py --mode lora
```

环境：GPU 4GB+ · PyTorch · API Key

场景选择建议

选传统ML

- 资源受限（无GPU、无网络）
- 受限公式类型 · 需要可解释性
- 教学演示 · 快速原型验证

选多模态大模型

- 高精度要求 · 开放公式类型
- 矩阵/复杂公式需要结构化输出
- 有GPU+API资源支持

两者互补

- 简单公式→传统ML（快速免费）
- 复杂公式→大模型（高精度）
- 两级级联覆盖全部场景

项目分工总览：各司其职，协同完成

A 项目负责人（张椅达）

- 整体架构设计与技术路线规划
- src/全部7个核心模块开发
- LoRA微调+DeepSeek混合方案
- 对比学习探索与评估分析
- 矩阵识别模型·报告撰写

工作量：~60%

B 传统ML开发（杨振凯）

- 数据预处理与数据增强
- HOG+LBP特征工程
- PCA降维与SVM模型训练
- 核函数对比与超参调优
- 14张可视化分析图

工作量：~25%

C 项目支持（钟京序）

- 参与选题分析与讨论
- PPT制作与内容组织
- CUDA环境配置与测试
- 实验结果整理与对比
- 文档维护与代码注释

工作量：~15%

总结

项目成果

- 完整实现2条技术路线 + 1条探索路线
- 多模态大模型准确率85.2% (921全量)
- 传统ML基线68.73% (30类)

关键技术突破

- LoRA微调: 0.3%参数·7分钟·20%→80.8%
- DeepSeek校正: +4.4% (80.8%→85.2%)
- 矩阵识别: 从0%到45.9% (范式质变)

技术演进脉络

四次跃迁:

- 特征: 手工设计 (HOG/LBP) → 自动学习 (Transformer)
- 模型: 浅层分类 (SVM) → 深层生成 (Seq2Seq Transformer)
- 能力: 模式匹配 → 语义理解 (DeepSeek协同)
- 结构泛化: 封闭分类 (矩阵不可识别) → 开放生成 (矩阵可识别45.9%)

传统ML适合受限场景 | 低成本·易部署·可解释

大模型适合开放场景 | 高精度·强泛化·可生成

两者互补, 覆盖从简单到复杂的全部公式识别需求

谢谢！

感谢聆听

从传统机器学习到多模态大模型的手写数学公式识别

2026年5月